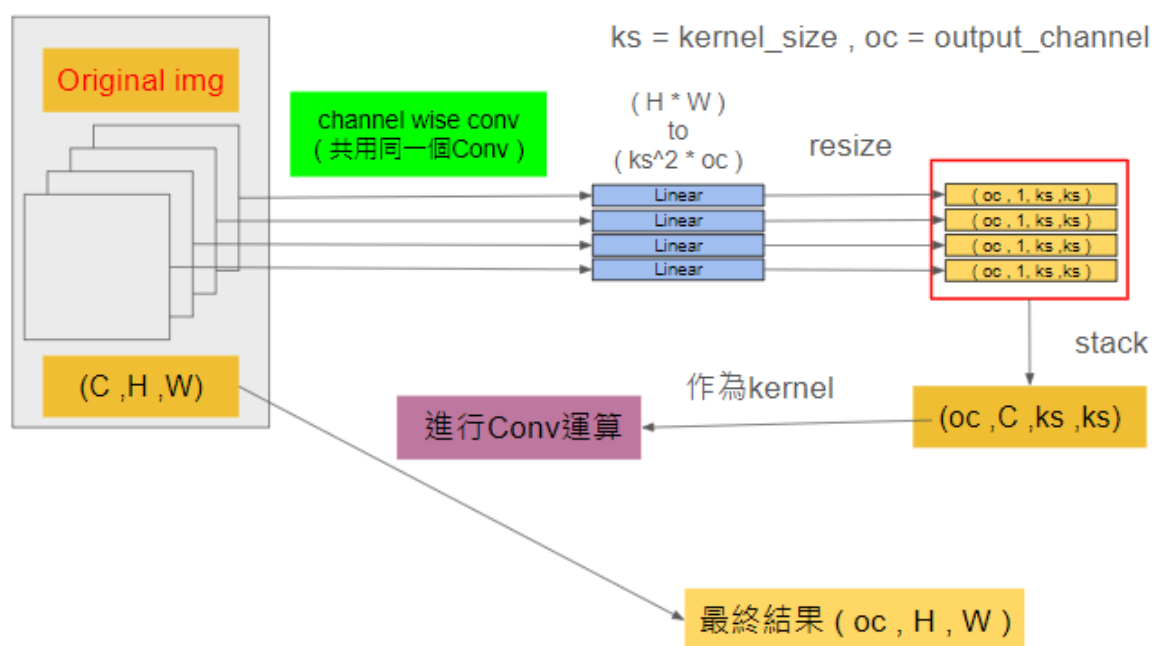


問題1;

設計一個Convolution Module, 且該Convolution Module可以處理多通道的輸入

方法:

以下是架構圖:



其主要的設計理念是:


給定一個channel的feature\_map, 就使用linear來產生該feature\_map的kernel, 再使用該kernel對原圖進行捲積, 即可達成處理多個Feature map 的資訊

Result

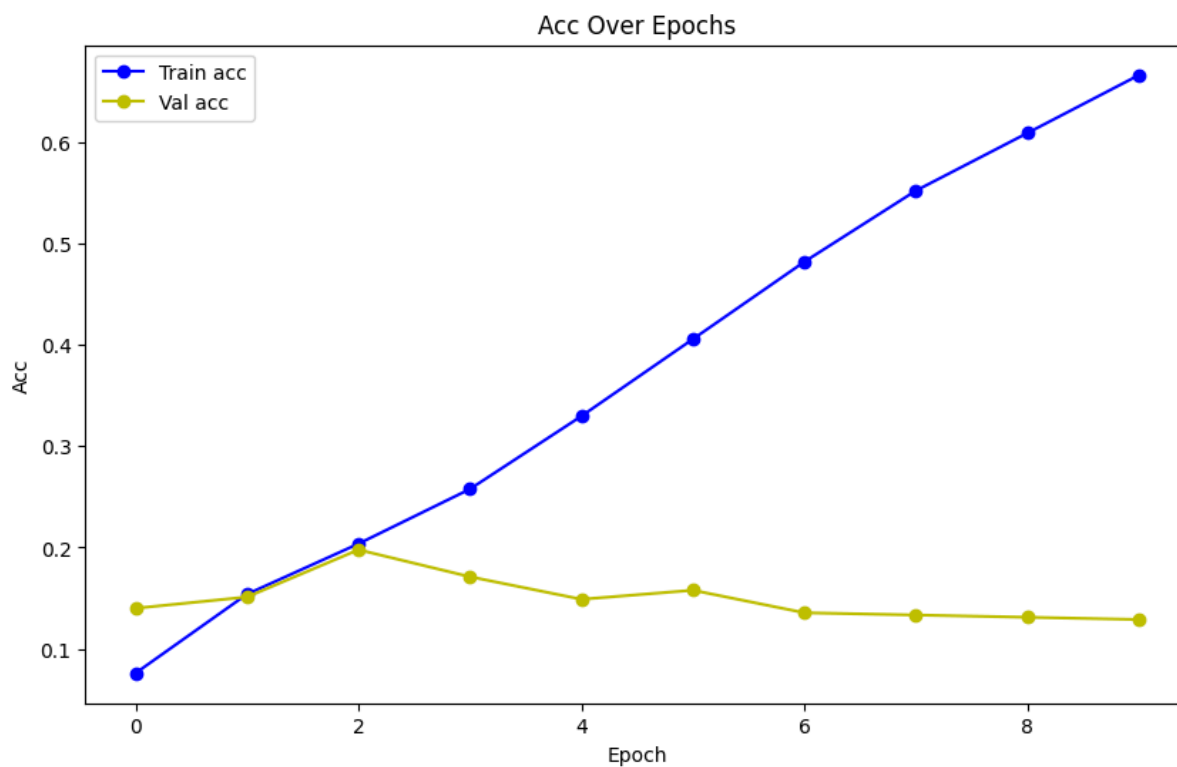
在**3\_channel**下的實驗:

**Flex\_channel\_CNN**

Loss Curve :

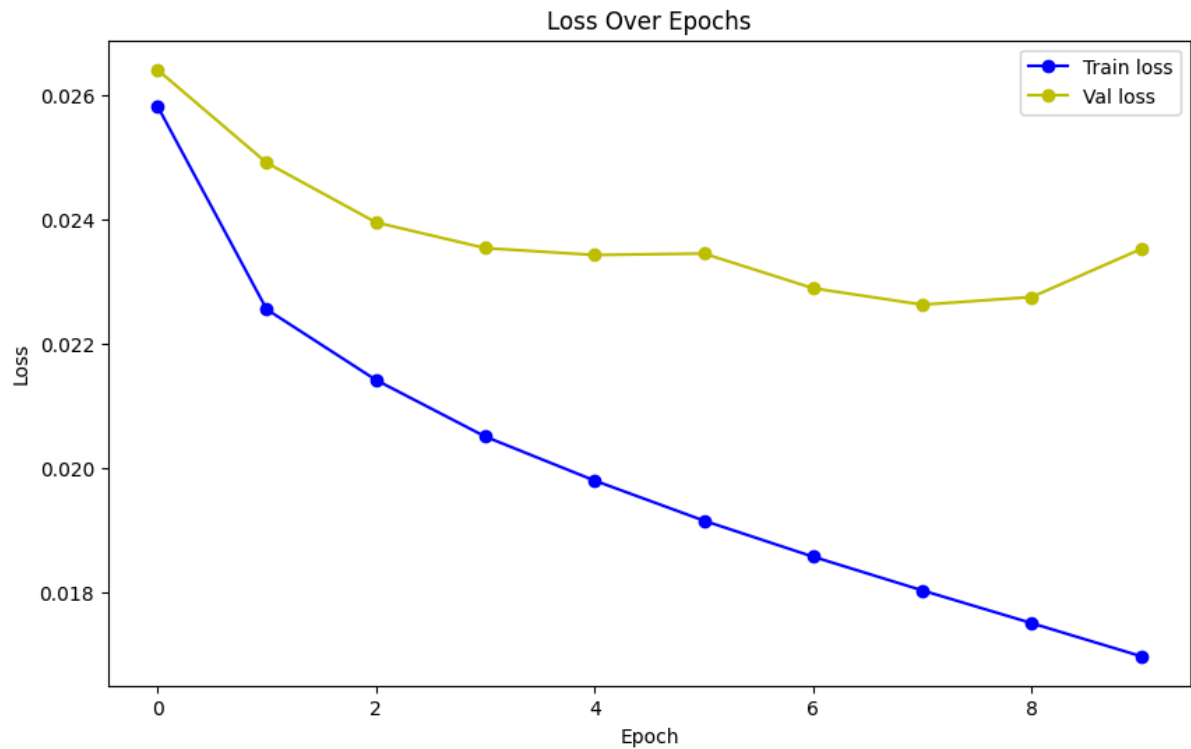


Accuracy Curve : val acc最高到0.19




### 3\_layer\_CNN

Loss Curve :



Accuracy Curve : val acc最高到0.29



## 參數量比較:

在輸入3\_channel, 圖片大小為( 128 , 128 , 3 )的狀況下

輸出channel數量為32, kernel\_size = 3\*3 , padding = 'same'

---

### 使用一般Conv方法

Conv2d(in\_channels=3, out\_channels=32, kernel\_size=3, padding = 'same')

即可達成

所使用的參數量為

$$\begin{aligned}\text{kernel部分} &= 3 (\text{輸入通道數}) * 3 * 3 (\text{kernel大小}) * 32 (\text{kernel數}) \\ &= 864\end{aligned}$$

$$\text{Bias 部分} = 32 (\text{kernel數})$$

$$\text{總共} : 864 + 32 = 896$$

---

### 若使用自創的方法

則是需要用到

Conv2d(in\_channels=1, out\_channels=1, kernel\_size=3, padding='same')

和 nn.Linear(width\*height, ks \* ks \* output\_channel)

**Conv**部分需要

$$\begin{aligned}\text{kernel部分} &= 1 (\text{輸入通道數}) * 3 * 3 (\text{kernel大小}) * 32 (\text{kernel數}) \\ &= 288\end{aligned}$$

$$\text{Bias 部分} = 32 (\text{kernel數})$$

$$\text{總共} : 288 + 32 = 320$$

**Linear**部分需要

Linear部分

$$\begin{aligned}&= 128 * 128 (\text{feature\_map大小}) * 3 * 3 (\text{kernel大小}) * 32 (\text{輸出channel數}) \\ &= 4718592\end{aligned}$$

$$\text{Bias 部分} = 32 (\text{輸出channel數})$$

$$\text{總共} : 4718592 + 32 = 4718624$$

---

討論：

原本的conv方法並不會受圖片大小的影響而增加參數量, 但會受輸入的圖片的channel數影響, 我的方法則相反, 不受輸入的圖片channel數影響參數量, 但會受到圖片大小影響, 故我的方法較適合用在經過多層捲積或者Maxpooling之後, 其圖片大小變得很小, 但其channel數很大的時候, 可以有效的節省參數。

## 問題2:

使用 2~4層的CNN layer, Transformer 或 RNN ,使其 performance到達Resnet34的90%

方法:

以下是print(model)的結果

```
DenseNet(  
  (conv1): Conv2d(3, 512, kernel_size=(7, 7), stride=(2, 2), padding=(2, 2), bias=False)  
  (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
  (pool1): MaxPool2d(kernel_size=3, stride=2, padding=1, dilation=1, ceil_mode=False)  
  (features): ModuleList(  
    (0): Sequential(  
      (0): Bottleneck(  
        (conv): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)  
        (bn): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
      )  
    )  
    (1): Transition(  
      (conv): Conv2d(1024, 512, kernel_size=(1, 1), stride=(1, 1), bias=False)  
      (bn): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
      (pool): AvgPool2d(kernel_size=2, stride=2, padding=0)  
    )  
    (2): Sequential(  
      (0): Bottleneck(  
        (conv): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)  
        (bn): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
      )  
    )  
  )  
  (bn2): BatchNorm2d(1024, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)  
  (fc): Linear(in_features=1024, out_features=50, bias=True)  
)
```

總共使用四層Conv2D的module

其設計方式為:

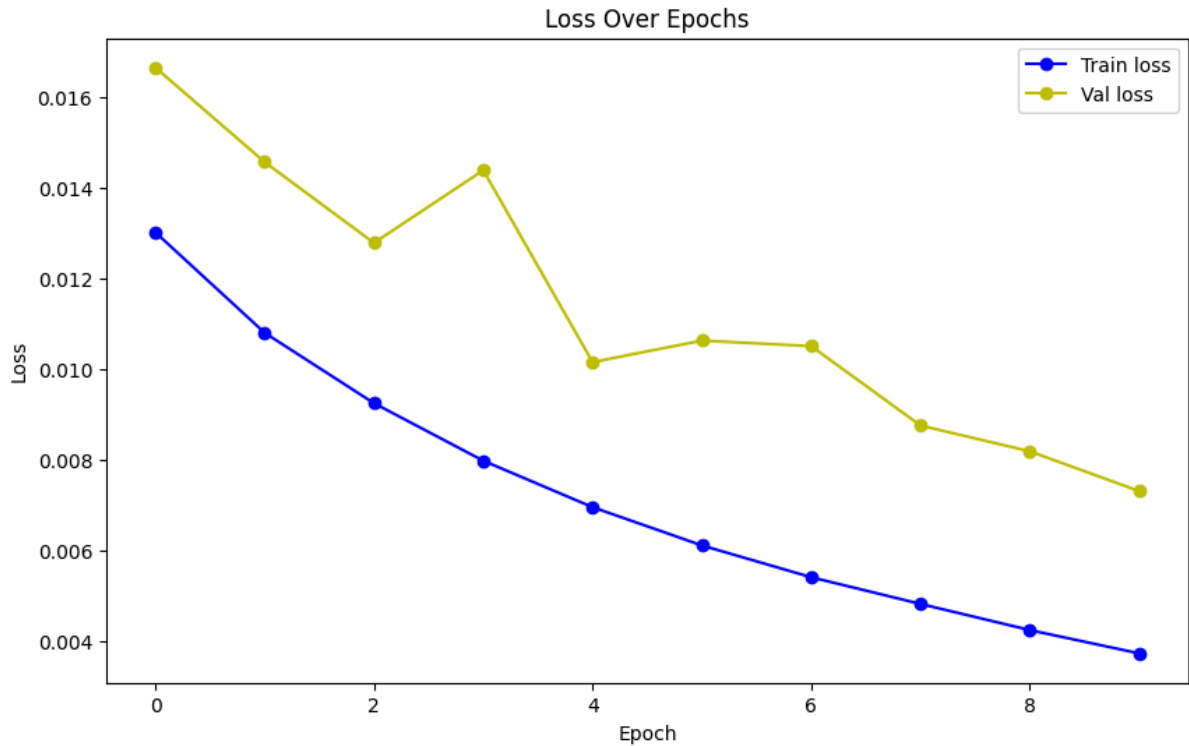
根據DenseNet的概念進行修改, 實際做法為

1. 經過第一層Conv2D使其從channel數從3->512
2. 經過BatchNorm標準化和MaxPool2D濃縮資訊
3. 經過第二層Conv2D產生channel 512的feature\_map
4. concat( 第一層Conv2D , 第二層Conv2D )channel為1024
5. 將concat後的結果過第三層Conv2D輸出為512channel
6. 經過BatchNorm標準化和MaxPool2D濃縮資訊
7. 將第三層Conv2D經過第四層Conv2D輸出為512channel
8. 經過BatchNorm標準化
9. concat( 第三層Conv2D , 第四層Conv2D )channel為1024
10. 經過BatchNorm標準化和Adaptive\_avg\_pooling
11. 最後經過Linear輸出結果

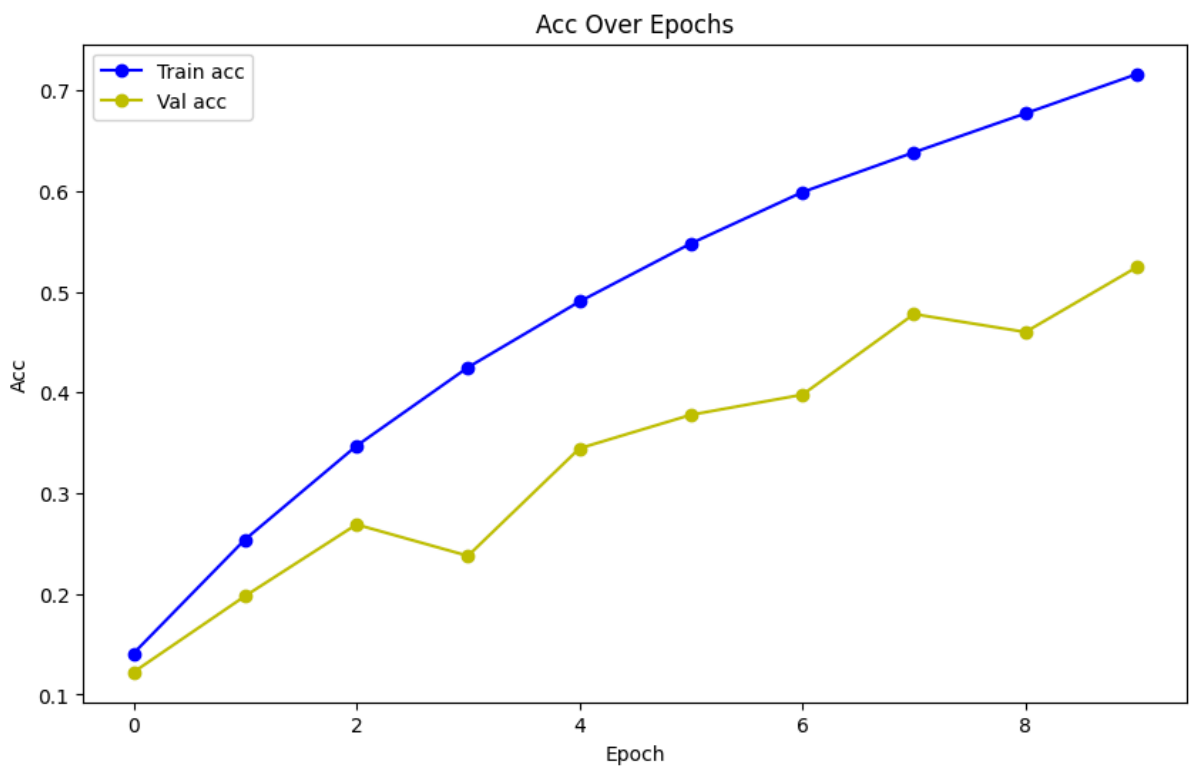
Result:

以下是2~4CNN\_model在10epochs內的結果

Loss Curve :




Accuracy Curve : 最高performance到達0.524 , testing\_acc為0.53



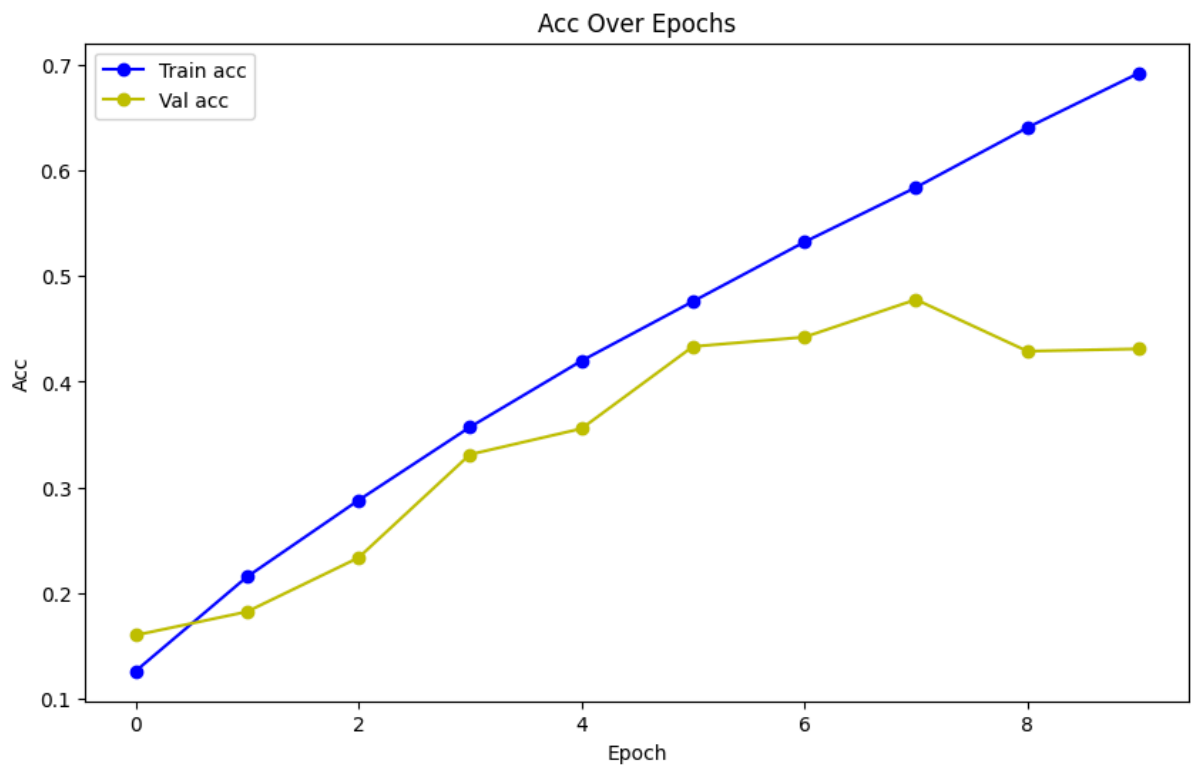
Result:

以下是**Resnet34**在10epochs內的結果

Loss Curve :



Accuracy Curve : 最高performance到達0.477 , testing\_acc為0.45



## 參數量

以下是2~4CNN\_model的參數量

```
=====
Total params: 5,375,538
Trainable params: 5,375,538
Non-trainable params: 0
Total mult-adds (G): 3.86
=====
```

以下是Resnet34的參數量

```
=====
Total params: 21,847,722
Trainable params: 21,847,722
Non-trainable params: 0
Total mult-adds (G): 1.20
=====
```

可以發現其自行設計模型的參數量約為Resnet34的**2.5**倍左右

才能達到和Resnet34相似的performance

這兩個模型本質上都是使用Conv. layer處理圖片的資訊

但這兩個模型在深度上有相當大的差距

可以推測說，在相同的參數下，將模型加深會比單純增加**kernel**數  
獲得更高的performance

解決問題的流程：

由於在限制下，只能使用2~4層的Conv2D，模型深度也沒有辦法太深，故只能從增加參數量下手，而當中有嘗試過CBAM，SENET這些增加channel之間關係，但這兩個方法一方面會用掉不少

Conv2D(CBAM的channel attention和spatial attention就要用掉3層，SENet就要用掉2層)，一方面他們的輸入輸出的Chanel數都相同，沒有辦法有效的擴大參數量，偶然之下發現一般疊四層一般的Conv2D經過BN和Maxpooling效果不錯，但仍未到達ResNet34的90%，後來嘗試看看DenseNet的方法，借用其**Concat**前面**layer**輸出的想法，可以更有效的利用前面layer的output，且也能解省Conv layer，也可以在硬體資源有限的情況下，擴大output的channel數量。

Github連結：

[https://github.com/IIRchen/Deep\\_Learning\\_HW2.git](https://github.com/IIRchen/Deep_Learning_HW2.git)